# 第七届江苏省大学生生物医学工程竞赛大一版指导方案

## 第七届江苏省大学生生物医学工程创新设计竞赛指导方案（大一版）

作为大一学生参与该竞赛，核心思路是**简化复杂流程、聚焦基础核心、夯实实操能力**，避开过于高深的算法和复杂的特征工程，以“可实现、逻辑完整、结果合理”为核心完成竞赛任务。以下从**竞赛核心认知、任务拆解、分阶段实施步骤、大一适配技巧、避坑要点**五个维度给出详细可落地的指导，全程贴合大一的编程、数学、专业知识储备（默认你有Python基础，无也可快速补学）。

### 一、先明确竞赛核心认知（避免走偏）

1. **核心任务**：用单导联脑电数据（Sleep-EDF数据集），以**30s为一帧**做睡眠分期多分类（仅分R/REM、N1、N2、N3四类），最终以**宏F1值**为评价标准，提交设计报告、全部代码、指定格式的预测结果文件。
2. **数据关键信息**
   - 原始数据：电压值(V)，采样频率100Hz → **30s一帧对应3000个数据点**（核心计算，必须记牢）；
   - 标签处理：删除标签为 `?` 的段数据，无需考虑体动/未知、清醒期(W)；
   - 数据集划分：训练集45例（13SC+32ST）拆为225组数据+标签，测试集6例（4ST+2SC）仅给初始清醒标签，需输出5个/例的预测txt。
3. **大一适配原则**：不追求SOTA（最优）模型效果，重点把**数据预处理→特征提取→模型训练→结果输出**的全流程跑通，保证代码可运行、报告逻辑完整、结果文件格式合规，这是拿基础分的关键。

### 二、竞赛全任务拆解（清晰做什么）

把竞赛要求拆解为**6个核心子任务**，按“从数据到结果”的顺序推进，每个子任务对应评分标准的得分点：

1. 数据读取与预处理（对应报告“数据分析与预处理”10分）；
2. 脑电信号滤波（竞赛强制要求，核心预处理步骤）；
3. 30s帧分割与标签匹配（核心数据处理，保证分类粒度正确）；
4. 脑电特征提取（大一版选**基础时域/频域特征**，避开复杂时频域）；
5. 简单模型训练与验证（大一版选**机器学习入门模型**，不碰深度学习）；

6. 测试集预测与结果文件生成（对应“实际测试”核心得分点）；
7. 设计报告撰写+代码整理（对应报告50分+代码10分）。

## 三、分阶段实施步骤（手把手教做，附大一适配技巧）

### 阶段1：环境搭建（1-2天，零基础可完成）

核心是搭建**Python数据分析+信号处理**的基础环境，选轻量化工具，避免复杂配置。

1. **软件安装**：安装Anaconda（自带Python+包管理，避免环境冲突），用Spyder或Jupyter Notebook编写代码（两款均为可视化界面，适合大一新手，比Pycharm简单）。
2. **核心包安装**（Anaconda终端输入命令，一键安装）：
   - 数据处理：`pandas`（读txt/处理表格）、`numpy`（数值计算，核心）；
   - 信号处理：`scipy`（滤波、信号特征计算，竞赛核心包）、`matplotlib`（画图，报告用）；
   - 机器学习：`sklearn`（scikit-learn，入门级机器学习库，自带模型+评估指标，无需自己写公式）。
3. **小测试**：写简单代码读取一个脑电txt文件，打印前10个数据点，确认环境无问题。

### 阶段2：数据读取与预处理（2-3天，核心是“读对、删错、理清楚”）

#### 2.1 读取数据

竞赛数据是**txt格式的原始脑电数据**和**标签txt**，用`numpy.loadtxt()`或`pandas.read_csv()`读取即可，大一重点掌握**按文件名匹配数据和标签**（如ST7011J0的Part1数据对应Part1标签）。

- 技巧：用Python的`os`库遍历文件夹，按“被试ID+Part_X”作为关键词，自动匹配数据和标签文件，避免手动逐个读取（节省时间，代码更规范）。

#### 2.2 标签清洗（竞赛强制要求）

标签txt的第四列为分类标签，需**删除标签为`?`的所有对应数据段**：

1. 读取标签文件，按列分割（开始时间、结束时间、持续时间、标签）；
2. 筛选出标签列≠`?`且标签∈[R,1,2,3]的行；
3. 根据筛选后的开始/结束时间，截取对应的脑电数据段（删除无用数据）。

- 大一简化：若时间戳处理困难，可直接按**标签的帧数量**匹配（如标签标注某段为30s×5帧=N2，则取对应5×3000个脑电数据点，标注为N2）。

#### 2.3 数据格式统一

将所有读取的脑电数据转为**numpy数组**（方便后续计算），标签转为**数字编码**（机器学习模型只认数字，大一必做）：

- 编码规则：R→0、N1→1、N2→2、N3→3（可自定义，记牢即可），用 `sklearn.preprocessing.LabelEncoder` 一键编码，无需自己写映射。

## 阶段3：脑电信号滤波（1-2天，竞赛强制要求，必须做）

原始脑电信号有噪声（如工频噪声50Hz、肌电噪声），需用**滤波**去除，`scipy.signal` 库自带滤波函数，大一选**基础的数字滤波器**，无需理解复杂的滤波原理，直接调包使用。

1. **脑电信号的滤波标准**：睡眠脑电常用**0.5-30Hz带通滤波**（保留睡眠分期相关的脑电波，如δ波、θ波、α波）；同时去除50Hz工频噪声（用50Hz陷波滤波）。
2. **大一版滤波代码**：直接调用 `scipy.signal.butter`（巴特沃斯带通滤波，最常用、最稳定）和 `scipy.signal.iirnotch`（陷波滤波），复制模板代码即可，只需修改**截止频率、采样频率**（采样频率100Hz是固定值）。
3. **验证滤波效果**：用 `matplotlib` 画出滤波前和滤波后的脑电信号波形，贴在报告中，体现“数据分析与预处理”的完整性。

## 阶段4：30s帧分割与标签匹配（1天，核心关键，不能错）

竞赛要求**30s脑电数据为一帧**，采样频率100Hz → **每帧必须是3000个连续数据点**，这是后续分类的基础，错了整个模型就无效。

1. **帧分割方法**：对滤波后的脑电数据，按**步长3000、窗口3000**进行滑动分割，得到一个个独立的30s帧（如15000个数据点→5帧）。
2. **标签匹配**：保证每个30s帧对应**唯一的标签（R/1/2/3）**，分割后检查“帧数量=标签数量”，避免数据和标签错位。

- 避坑：若最后一段数据不足3000个点，直接删除（保证每帧都是3000个点，统一规格）。

## 阶段5：特征提取（2-3天，大一版“极简特征集”，易实现、效果稳）

脑电信号是**时序信号**，直接用原始3000个数据点训练模型会出现“维度爆炸”，需提取**特征**（用少数数字代表一帧的信号特征），这是生物医学信号处理的核心。

**大一绝对不要碰复杂特征**（如小波变换、熵特征、时频域特征），选**时域+频域基础特征**，共10-15个，易计算、代码量少，且能满足竞赛基本要求，`scipy` 和 `numpy` 可直接计算。

### 5.1 时域特征（反映信号的统计规律，最易计算）

对每帧3000个数据点，计算以下特征：

- 统计特征：均值、方差、标准差、最大值、最小值、中位数、绝对偏差；
- 波形特征：峰度、偏度（`scipy.stats` 库一键计算）。

### 5.2 频域特征（反映脑电的频率分布，睡眠分期的核心依据）

睡眠分期的本质是脑电波的频率差异（如N3期以δ波0.5-4Hz为主，REM期以θ波4-8Hz为主），只需计算**各频率段的功率谱密度(PSD)**，大一版简化为：

1. 用 `scipy.signal.welch` 计算每帧的功率谱密度（PSD），得到“频率-功率”对应关系；
2. 按睡眠脑电波频段分割，计算**各频段的平均功率**（核心特征，共5个）：
   - δ波：0.5-4Hz、θ波：4-8Hz、α波：8-13Hz、β波：13-30Hz、γ波：30Hz以上（仅计算前4个即可，γ波无意义）；
3. 把各频段功率的**占比**也作为特征（如δ波功率/总功率），提升特征区分度。

### 5.3 特征整理

将每帧的**时域特征+频域特征**拼接为一个**特征向量**（如10个时域+4个频域=14维特征向量），最终得到**样本数×特征维度**的特征矩阵，作为模型的输入。

## 阶段6：模型训练与验证（2-3天，大一版“入门机器学习模型”，零公式）

竞赛是**4分类任务**，大一**绝对不要碰深度学习**（如CNN、LSTM，需要大量数据、调参能力，且大一知识储备不足），选 `sklearn` 库中的**入门级机器学习模型，逻辑回归/支持向量机(SVM)/随机森林**三选一即可，其中**随机森林（Random Forest）** 是最优选择（抗噪声、无需特征归一化、分类效果稳，调参简单）。

### 6.1 数据划分

将训练集的**特征矩阵+标签**按**7:3**划分为**训练集+验证集**（`sklearn.model_selection.train_test_split` 一键划分），验证集用于评估模型效果，避免过拟合。

- 可选优化：做**特征归一化**（`sklearn.preprocessing.StandardScaler`），将特征缩放到同一范围，提升模型收敛速度，代码只需2行，建议加上。

### 6.2 模型训练

以**随机森林**为例，大一版代码仅需3行，无需理解模型原理：

Code block

```
from sklearn.ensemble import RandomForestClassifier
# 定义模型（n_estimators为树的数量，大一设为100即可，默认值）
model = RandomForestClassifier(n_estimators=100, random_state=42)
# 训练模型
model.fit(X_train, y_train)
```

- 调参简化：仅调整 `n_estimators`（如50、100、200），选验证集效果最好的即可，无需复杂调参。

### 6.3 模型评估（计算宏F1值，竞赛核心评价标准）

用验证集的预测结果计算**宏F1值**，`sklearn`自带函数，**无需自己写precision/recall/F1公式**，大一直接调包：

Code block

```
from sklearn.metrics import f1_score
# 验证集预测
y_pred = model.predict(X_val)
# 计算宏F1值（average='macro'是竞赛要求的宏F1，必须写对）
macro_f1 = f1_score(y_val, y_pred, average='macro')
print(f"验证集宏F1值：{macro_f1:.4f}")
```

- 目标：宏F1值达到0.6以上即可（大一水平，竞赛不会要求过高），若低于0.6，可增加2-3个特征（如均方根、平均绝对偏差）。
- 报告必备：画出**混淆矩阵**（`sklearn.metrics.confusion_matrix`），用`matplotlib`可视化，体现模型对每一类的分类效果，是报告的加分项。

## 阶段7：测试集预测与结果文件生成（1-2天，竞赛提分关键，格式必须合规）

测试集无标签（仅给初始清醒期标签），需用训练好的模型对测试集的6例数据做预测，并按**竞赛指定格式**生成txt文件，这一步**格式大于效果**，哪怕预测效果一般，格式合规就能拿分。

### 7.1 测试集处理流程

完全复用训练集的处理流程：**读取测试集脑电数据→滤波→30s帧分割→提取相同的特征→模型预测**，保证**特征维度、滤波参数、帧分割规则**和训练集完全一致（否则预测无效）。

### 7.2 结果文件生成（严格按竞赛要求）

1. 新建文件夹，命名为**results**（必须同名）；
2. 对测试集每一例数据，生成**5个txt文件**，命名格式为：`被试ID_Hypnogram_Data_Part_X_of_5.txt`（如ST7012J0_Hypnogram_Data_Part_1_of_5.txt）；
3. 每个txt文件的内容：按竞赛标签格式，包含**开始时间、结束时间、持续时间、预测标签**（R/1/2/3），时间戳可按30s为步长生成（如Part1的第一帧开始时间0s、结束时间30s、持续时间30s，第二帧30s-60s，以此类推）；
4. 6例数据共30个txt文件，全部放入`results`文件夹，无多余文件、无命名错误。

## 阶段8：设计报告撰写+代码整理（3-4天，50+10分，大一重点“逻辑完整、图文并茂”）

竞赛报告是评分的核心，大一撰写无需高深的专业分析，重点**结构清晰、步骤完整、图文结合、代码注释详细**，严格对应竞赛的评分点（问题定义与分析、数据分析与预处理、模型设计与选择、实验测试），以下是报告的**标准化框架**（直接套用）：

### 报告框架（总字数2000-3000字即可，大一无需长篇大论）

1. **摘要**（150字）：简述竞赛任务、所用方法（滤波+特征提取+随机森林）、实验结果（验证集宏F1值）、最终结论；
2. **一、问题定义与分析**（对应10分）：阐述睡眠监测的背景、单导联脑电的优势、竞赛的核心任务（30s帧4分类）、评价标准（宏F1）；
3. **二、数据分析与预处理**（对应10分）：介绍数据集（Sleep-EDF）、数据读取方法、标签清洗、滤波处理（附滤波前后波形图）、30s帧分割（附分割流程）；
4. **三、特征提取**（归为预处理，或单独一节）：介绍所选的时域/频域特征、计算方法（附特征统计图表）；
5. **四、模型设计与选择**（对应10分）：说明选择随机森林的原因（大一适配、抗噪声、效果稳）、模型原理（简单介绍，无需公式）、模型参数设置；
6. **五、实验测试**（对应10分）：介绍数据划分方法、模型训练过程、验证集评估结果（附宏F1值、混淆矩阵图）、测试集预测流程；
7. **六、实验结果与分析**：展示测试集预测结果、文件生成格式，分析模型的优点与不足（大一可写“特征较少、模型简单，后续可增加特征/优化模型”）；
8. **七、总结与展望**：总结本次竞赛的完成情况，展望后续可改进的方向；
9. **参考文献**（3-5篇，知网搜“睡眠分期 单导联脑电 机器学习”，抄录格式即可）；
10. **附录**：附上全部代码（带详细注释）。

### 代码整理要求

1. 代码按**阶段分模块**编写（数据读取、滤波、帧分割、特征提取、模型训练、预测输出），每个模块加注释；
2. 代码可**一键运行**（避免手动修改路径、参数），用 `os.path.join()` 设置文件路径，适配不同电脑；
3. 加入**异常处理**（如文件不存在、数据不足3000个点），避免代码运行报错，体现编程素养。

## 四、大一专属适配技巧（避坑+提分，核心）

1. **拒绝“炫技”**：不碰深度学习、小波变换、复杂调参，把基础流程跑通是第一位，竞赛评委对大一学生的预期是“掌握基础方法，逻辑完整”，而非“最优效果”；
2. **善用“调包”**：所有公式、算法都用Python库自带函数，无需自己实现，大一的核心是**理解流程、会调用工具**，而非手写底层代码；

3. **复用代码模板**：滤波、特征提取、模型训练、宏F1计算都有成熟的入门模板，直接修改参数即可，节省时间；
4. **重点检查“格式”**：结果文件的命名、文件夹名称、txt内容格式必须严格按竞赛要求，这是“硬指标”，格式错误会直接丢分；
5. **图文并茂**：报告中多放图（滤波波形、混淆矩阵、特征分布、帧分割示意图），少写大段文字，评委更关注可视化结果；
6. **团队分工（若有队友）**：若为团队参赛，按“数据处理→特征提取→模型训练→报告撰写”分工，每人负责一个模块，避免重复工作，大一团队建议2-3人，不宜过多。

## 五、常见避坑要点（绝对不能犯的错误）

1. **帧分割错误**：每帧不是3000个数据点（如按1s/10s分割），这是核心错误，直接导致模型无效；
2. **标签处理错误**：未删除 `?` 标签，或包含了清醒期(W)标签；
3. **未做滤波**：竞赛强制要求“先滤波再训练”，未滤波会导致模型效果极差，且报告中无滤波步骤会丢分；
4. **宏F1计算错误**：`sklearn` 中 `average` 参数设为 `micro` / `weighted`，而非 `macro`，必须严格设为 `macro`；
5. **结果文件格式错误**：文件夹名不是 `results`、文件命名不规范、txt内容缺少列（如无开始时间）；
6. **特征不一致**：测试集提取的特征和训练集不一致（如训练集提了14个特征，测试集提了10个），导致预测报错。

## 六、时间规划（总周期15-20天，适合大一课余时间）

按大一**每天1-2小时**的课余时间规划，可灵活调整：

1. 第1-2天：环境搭建+数据读取入门；
2. 第3-5天：数据预处理+标签清洗+滤波；
3. 第6-7天：30s帧分割+标签匹配；
4. 第8-10天：特征提取（时域+频域）；
5. 第11-13天：模型训练+验证集评估（宏F1计算）；
6. 第14-15天：测试集预测+结果文件生成；
7. 第16-20天：报告撰写+代码整理+格式检查。

## 最后寄语

作为大一学生，参与该竞赛的**核心收获不是拿大奖，而是掌握生物医学工程的基础研究方法**（信号处理+机器学习+数据分析），这比竞赛结果更重要。评委对大一学生的评判标准会远低于高年级，只要

你能把全流程跑通，提交合规的结果文件和逻辑完整的报告，就能取得不错的成绩。

如果在某个步骤（如滤波代码、帧分割、宏F1计算）遇到具体问题，可针对性攻克，优先保证“完成”而非“完美”！

我可以帮你编写**第一阶段的环境测试+数据读取基础代码**，直接适配竞赛的txt格式数据，你只需替换文件路径即可运行，需要吗？

（注：文档部分内容可能由 AI 生成）